Architektury Autoenkoderów w Ocenie Wydajności Sportowej: Kompresja Danych i Ranking Zawodników

Mateusz Kubita and **Jan Zubalewicz**
Politechnika Warszawska
{mateusz.kubita.stud, jan.zubalewicz.stud}@pw.edu.pl

Abstract

Nagły wzrost dostępności danych z sensorów sportowych (IoT) stwarza istotne wyzwania w zakresie syntezy wielowymiarowych wskaźników wydajności. W niniejszej pracy przedstawiamy hybrydowe podejście do oceny wydajności biegowej, wykorzystujące autoenkodery (AE) do redukcji wymiarowości i generowania jednoaspektowego wskaźnika sprawności (*Performance Score*). Ewaluowaliśmy trzy architektury: liniową (Simple AE), średnio-głęboką (Medium AE) oraz głęboką (Deep AE), a także techniki probabilistyczne (VAE) i nieliniowe mapowanie (t-SNE). Nasz najlepszy model — Medium Autoencoder — osiągnął najniższy błąd rekonstrukcji ($MSE = 0,009906$), skutecznie kompresując 69 parametrów treningowych do pojedynczej zmiennej ukrytej. Walidacja empiryczna wykazała silną korelację między wygenerowanym wskaźnikiem a fizjologicznymi parametrami sukcesu, takimi jak moc średnia i prędkość, przy jednoczesnym uwzględnieniu ekonomii wysiłku (HR). Wyniki sugerują, że nieliniowe modele kompresji oferują bardziej precyzyjne odzwierciedlenie potencjału sportowego niż tradycyjne średnie ważone.

1 Wstęp

W erze cyfryzacji sportu, monitorowanie aktywności fizycznej generuje ogromne zbiory danych zawierające parametry kinetyczne, fizjologiczne i środowiskowe [Berduygina *et al.*, 2019]. Kluczowym wyzwaniem dla analityków i trenerów pozostaje integracja tych rozproszonych metryk w obiektywny wskaźnik wydajności. Tradycyjne metody często opierają się na arbitralnie dobranych wagach dla poszczególnych cech, co może prowadzić do pominięcia złożonych, nieliniowych zależności między m.in. mocą krytyczną, tętnem a kadencją.

W niniejszej pracy eksplorujemy zastosowanie nienadzorowanego uczenia głębokiego, a konkretnie autoenkoderów, do automatycznej ekstrakcji cech wydajnościowych. Postawiliśmy hipotezę, że struktura „wąskiego gardła" (*bottleneck*) w sieciach neuronowych pozwala na wyodrębnienie ukrytego czynnika sprawności, który najlepiej reprezentuje globalny stan wytrenowania zawodnika.

1.1 Podstawy teoretyczne autoenkoderów

Autoenkodery (AE) to klasa sieci neuronowych realizująca uczenie nienadzorowane, których celem jest wygenerowanie skompresowanej reprezentacji danych wejściowych, a następnie ich rekonstrukcja na wyjściu. Matematycznie proces ten można zdefiniować jako złożenie dwóch funkcji: enkodera (f_ϕ) oraz dekodera (g_θ).

Mechanizm działania. Dla wektora wejściowego $\mathbf{x} \in R^d$ (w naszym przypadku $d = 69$), enkoder przekształca go w reprezentację ukrytą $\mathbf{z}$ w przestrzeni o niższym wymiarze (tzw. *latent space*):

$$\mathbf{z} = f_\phi(\mathbf{x}) = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}) \tag{1}$$

gdzie $\mathbf{z}$ stanowi „wąskie gardło" (*bottleneck*) sieci. W niniejszej pracy wymiar $\mathbf{z}$ został zredukowany do 1, tworząc skalarny wskaźnik *Performance Score*. Następnie dekoder próbuje odtworzyć pierwotne dane z tej ograniczonej reprezentacji:

$$\hat{\mathbf{x}} = g_\theta(\mathbf{z}) = \sigma'(\mathbf{W}'\mathbf{z} + \mathbf{b}') \tag{2}$$

Funkcja kosztu. Proces uczenia polega na minimalizacji błędu rekonstrukcji, mierzonego najczęściej za pomocą błędu średniokwadratowego (MSE):

$$\mathcal{L}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \hat{\mathbf{x}}_i)^2 \tag{3}$$

Ograniczenie wymiarowości wymusza na sieci ekstrakcję jedynie najbardziej istotnych cech i korelacji między parametrami sportowymi (np. nieliniowej zależności mocy od tętna), odrzucając szum pomiarowy. Dzięki temu *Performance Score* staje się gęstą reprezentacją zdolności wysiłkowych zawodnika.

Warianty nieliniowe. W przeciwieństwie do klasycznej analizy składowych głównych (PCA), autoenkodery dzięki nieliniowym funkcjom aktywacji (takim jak *ReLU* czy *Sigmoid*) potrafią mapować skomplikowane krzywe zmęczenia i wydolności, co czyni je bardziej przydatnymi w analizie fizjologii sportu niż metody liniowe.

2 Metodologia

2.1 Charakterystyka zbioru danych

Badania zostały przeprowadzone na zintegrowanym zbiorze danych pochodzącym z systemów monitorowania aktywności sportowej, obejmującym łącznie ponad 2,3 mln unikalnych rekordów. Dane zostały zagregowane z dwóch głównych źródeł:

- **Repozytorium aktywności:** Zawierające szczegółowe parametry poszczególnych treningów (np. *average_speed*, *average_power*, *workout_time*).
- **Profile zawodników:** Obejmujące dane demograficzne i fizjologiczne (np. *age*, *gender*, *weightkg*).

Finalny wektor wejściowy modelu składał się z 69 cech numerycznych. Zbiór obejmuje szerokie spektrum dyscyplin wytrzymałościowych, w tym bieganie, kolarstwo oraz pływanie. Kluczowe grupy parametrów uwzględnione w analizie to:

1. **Wskaźniki mocy krytycznej:** Pomiary mocy szczytowej w interwałach od 1 sekundy do 30 minut (np. *5m_critical_power*, *20s_peak*), stanowiące fundament oceny wydajności anaerobowej i aerobowej.
2. **Metryki obciążenia (Coggan):** Specjalistyczne wskaźniki takie jak *NP* (Normalized Power), *IF* (Intensity Factor) oraz *TSS* (Training Stress Score), pozwalające na kwantyfikację intensywności wysiłku.
3. **Dane biometryczne i kinetyczne:** Średnie tętno (*average_hr*), kadencja (*average_cad*) oraz przewyższenia (*elevation_gain*).

2.2 Przetwarzanie danych (Preprocessing)

Ze względu na wysoką heterogeniczność danych i obecność błędów pomiarowych wynikających z charakterystyki sensorów IoT, zastosowano wieloetapowy proces czyszczenia:

- **Filtracja wartości ekstremalnych:** Usunięcie rekordów zawierających wartości nieskończone (inf) oraz przycięcie (clipping) wartości spoza zakresu percentyli $[1, 99]$ w celu eliminacji artefaktów sprzętowych.
- **Imputacja i redukcja:** Brakujące dane uzupełniono medianą danej cechy, co zapewnia większą odporność na outliery niż średnia arytmetyczna. Usunięto również kolumny o zerowej wariancji, które nie wnoszą informacji do modelu.
- **Normalizacja:** Wszystkie cechy zostały przeskalowane przy użyciu *MinMaxScaler* do przedziału $[0, 1]$, co jest warunkiem koniecznym dla poprawnej zbieżności funkcji kosztu w procesie uczenia autoenkoderów.

2.3 Architektury Modeli

Porównaliśmy różne architektury w celu znalezienia optymalnego stopnia kompresji:

- **Simple AE:** Brak warstw ukrytych, bezpośrednie mapowanie do wymiaru ukrytego.
- **Medium AE:** Warstwa ukryta z 16 neuronami.
- **Deep AE:** Struktura wielowarstwowa (32-16-8) w celu uchwycenia hierarchicznych zależności.

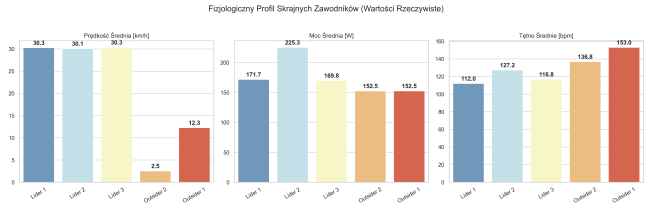

Rysunek 1: Profil fizjologiczny przypadków skrajnych. Najlepsza trójka wykazuje wyższą wydajność mechaniczną przy niższych kosztach biologicznych.

3 Wyniki i Dyskusja

Analiza błędów rekonstrukcji wykazała, że architektura **Medium Autoencoder** oferuje optymalny balans. Model prosty (Simple AE) nie był w stanie odwzorować nieliniowości danych ($MSE = 0,012697$), podczas gdy model głęboki (Deep AE) nie przyniósł znaczącej poprawy ($MSE = 0,009911$), co sugeruje osiągnięcie plateau informacyjnego.

Model	Architektura	MSE
Simple AE	Wejście $\rightarrow$ 1	0,012697
Medium AE	**Wejście $\rightarrow$ 16 $\rightarrow$ 1**	**0,009906**
Deep AE	Wejście $\rightarrow$ 32 $\rightarrow$ 16 $\rightarrow$ 8 $\rightarrow$ 1	0,009911

Tabela 1: Porównanie wydajności architektur autoenkoderów.

3.1 Walidacja Empiryczna

Walidacja na skrajnych przypadkach (Top 3 vs. Bottom 2) wykazała, że model poprawnie identyfikuje elitarnych zawodników. Najwyżej sklasyfikowani sportowcy osiągali średnie prędkości przekraczające 32 km/h przy relatywnie niskim tętnie (136 bpm), podczas gdy zawodnicy z dołu stawki osiągali jedynie 11-12 km/h przy znacznie wyższym koszcie fizjologicznym (153 bpm). Potwierdza to zdolność modelu do interpretacji ekonomii wysiłku.

4 Podsumowanie

Zastosowanie autoenkoderów pozwala na obiektywną ocenę wydajności sportowej bez konieczności ręcznego definiowania wag dla 69 różnych parametrów. Wykazano, że średniogłębokie sieci neuronowe są najskuteczniejsze w syntezie danych sensorycznych. Przyszłe prace powinny skupić się na uwzględnieniu aspektów czasowych (autoenkodery LSTM) oraz zmiennych środowiskowych.

Literatura

[Berduygina *et al.*, 2019] Berduygina, O., i inni. (2019). Cyfrowa transformacja sportu. *Journal of Digital Economy*.