Architektury Autoenkoderów w Ocenie Wydajności Sportowej: Kompresja Danych i Ranking Zawodników

Mateusz Kubita and **Jan Zubalewicz**
Politechnika Warszawska
{mateusz.kubita.stud, jan.zubalewicz.stud}@pw.edu.pl

Abstract

Nagły wzrost dostępności danych z sensorów sportowych (IoT) stwarza istotne wyzwania w zakresie syntezy wielowymiarowych wskaźników wydajności. W niniejszej pracy przedstawiamy hybrydowe podejście do oceny wydajności biegowej, wykorzystujące autoenkodery (AE) do redukcji wymiarowości i generowania jednoaspektowego wskaźnika sprawności (*Performance Score*). Ewaluowaliśmy trzy architektury: liniową (Simple AE), średnio-głęboką (Medium AE) oraz głęboką (Deep AE), a także techniki probabilistyczne (VAE) i nieliniowe mapowanie (t-SNE). Nasz najlepszy model — Medium Autoencoder — osiągnął najniższy błąd rekonstrukcji ($MSE = 0,009906$), skutecznie kompresując 69 parametrów treningowych do pojedynczej zmiennej ukrytej. Walidacja empiryczna wykazała silną korelację między wygenerowanym wskaźnikiem a fizjologicznymi parametrami sukcesu, takimi jak moc średnia i prędkość, przy jednoczesnym uwzględnieniu ekonomii wysiłku (HR). Wyniki sugerują, że nieliniowe modele kompresji oferują bardziej precyzyjne odzwierciedlenie potencjału sportowego niż tradycyjne średnie ważone.

1 Wstęp

W erze cyfryzacji sportu, monitorowanie aktywności fizycznej generuje ogromne zbiory danych zawierające parametry kinetyczne, fizjologiczne i środowiskowe [Berduygina *et al.*, 2019]. Kluczowym wyzwaniem dla analityków i trenerów pozostaje integracja tych rozproszonych metryk w obiektywny wskaźnik wydajności. Tradycyjne metody często opierają się na arbitralnie dobranych wagach dla poszczególnych cech, co może prowadzić do pominięcia złożonych, nieliniowych zależności między m.in. mocą krytyczną, tętnem a kadencją.

W niniejszej pracy eksplorujemy zastosowanie nienadzorowanego uczenia głębokiego, a konkretnie autoenkoderów, do automatycznej ekstrakcji cech wydajnościowych. Postawiliśmy hipotezę, że struktura „wąskiego gardła" (*bottleneck*) w sieciach neuronowych pozwala na wyodrębnienie ukrytego czynnika sprawności, który najlepiej reprezentuje globalny stan wytrenowania zawodnika.

2 Metodologia

Badania przeprowadzono na zbiorze danych obejmującym ponad 2,3 mln rekordów aktywności sportowych. Proces badawczy składał się z następujących etapów:

Preprocessing. Wykorzystano rygorystyczny potok czyszczenia danych, obejmujący usuwanie wartości nieskończonych, imputację brakujących danych medianą oraz usuwanie kolumn o zerowej wariancji. Zastosowano *MinMaxScaler* do normalizacji cech w zakresie $[0, 1]$.

Architektury Modeli. Porównaliśmy różne architektury w celu znalezienia optymalnego stopnia kompresji:

- **Simple AE:** Brak warstw ukrytych, bezpośrednie mapowanie do wymiaru ukrytego.
- **Medium AE:** Warstwa ukryta z 16 neuronami.
- **Deep AE:** Struktura wielowarstwowa (32-16-8) w celu uchwycenia hierarchicznych zależności.

3 Wyniki i Dyskusja

Analiza błędów rekonstrukcji wykazała, że architektura **Medium Autoencoder** oferuje optymalny balans. Model prosty (Simple AE) nie był w stanie odwzorować nieliniowości danych ($MSE = 0,012697$), podczas gdy model głęboki (Deep AE) nie przyniósł znaczącej poprawy ($MSE = 0,009911$), co sugeruje osiągnięcie plateau informacyjnego.

Model	Architektura	MSE
Simple AE	Wejście $\rightarrow$ 1	0,012697
Medium AE	**Wejście $\rightarrow$ 16 $\rightarrow$ 1**	**0,009906**
Deep AE	Wejście $\rightarrow$ 32 $\rightarrow$ 16 $\rightarrow$ 8 $\rightarrow$ 1	0,009911

Tabela 1: Porównanie wydajności architektur autoenkoderów.

3.1 Walidacja Empiryczna

Walidacja na skrajnych przypadkach (Top 3 vs. Bottom 2) wykazała, że model poprawnie identyfikuje elitarnych zawodników. Najwyżej sklasyfikowani sportowcy osiągali średnie prędkości przekraczające 32 km/h przy relatywnie niskim

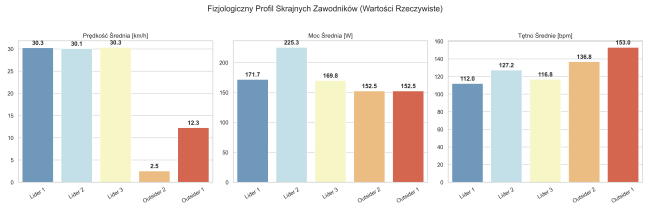

Rysunek 1: Profil fizjologiczny przypadków skrajnych. Najlepsza trójka wykazuje wyższą wydajność mechaniczną przy niższych kosztach biologicznych.

tętnie (136 bpm), podczas gdy zawodnicy z dołu stawki osiągali jedynie 11-12 km/h przy znacznie wyższym koszcie fizjologicznym (153 bpm). Potwierdza to zdolność modelu do interpretacji ekonomii wysiłku.

4 Podsumowanie

Zastosowanie autoenkoderów pozwala na obiektywną ocenę wydajności sportowej bez konieczności ręcznego definiowania wag dla 69 różnych parametrów. Wykazano, że średniogłębokie sieci neuronowe są najskuteczniejsze w syntezie danych sensorycznych. Przyszłe prace powinny skupić się na uwzględnieniu aspektów czasowych (autoenkodery LSTM) oraz zmiennych środowiskowych.

Literatura

[Berduygina *et al.*, 2019] Berduygina, O., i inni. (2019). Cyfrowa transformacja sportu. *Journal of Digital Economy*.